

Scheduled Sampling 을 적용한 ConvLSTM 기반 2 차원 난류의 와류장 자기회귀 예측 모델

김주성*

* 경희대학교 기계공학과

ConvLSTM-Based Autoregressive Prediction Model for Two-Dimensional Turbulent Vorticity Field with Scheduled Sampling

Ju Seong Kim*

* Dept. of Mechanical Engineering, Kyunghee Univ.,

(Received Jun 19, 2025)

Key Words: Autoregression(자기회귀), ConvLSTM, Scheduled Sampling

초록: 본 연구에서는 2 차원 난류의 와류장을 시계열적으로 예측하기 위한 딥러닝 기반의 Autoregression 모델을 제안한다. 모델은 ConvLSTM 아키텍처를 기반으로 하며 세 장의 와류장을 입력으로 다음 5 시점의 와류장을 예측하는 구조로 구성되어 있다. 순차 예측 시 발생하는 정답 의존성(Ground Truth Dependency)을 줄이기 위해 Scheduled Sampling 기법을 학습에 적용하여 학습이 진행될수록 정답 입력 대신 모델의 예측값을 점진적으로 사용하는 방식으로 학습 안정성과 일반화 성능을 향상시켰다. 학습 데이터는 OpenFOAM 을 통해 생성된 DNS 기반의 2 차원 난류 데이터를 활용하였으며, 주로 난류가 점차 소멸되는 마지막 10 초 구간의 데이터를 사용하였다.

Abstract: This study proposes a deep learning-based autoregressive model for sequential prediction of two-dimensional turbulent vorticity fields. The model adopts a ConvLSTM architecture, taking three consecutive vorticity frames as input to predict the next five time steps. To mitigate ground truth dependency during sequential prediction, the Scheduled Sampling technique is employed, gradually replacing ground truth inputs with the model's own predictions as training progresses. This approach enhances both training stability and generalization performance. The training dataset consists of DNS-based two-dimensional turbulence data generated using OpenFOAM, with a focus on the final 10 seconds of the simulation, where turbulence gradually decays.

- 기호설명 -[기호설명 제목: 돈움체, 10Point 줄간격
1.1, 가운데 맞춤]

여기에 기호 설명을 입력하십시오(설명은 반드시

1. 서 론

1.1 Introduction

유체역학에서 난류는 비선형성과 에너지 스케일의 다양성으로 인해 해석이 매우 어려운 현상 중 하나로 꼽힌다. 특히 2 차원 난류는 에너지의 역전달(inverse cascade)⁽¹⁾ 과 같은 고유한 동역학을 보여주며 와류 구조의 시간적 진화를 정확히 포착하는 것은 난류 이해와 예측에서 중요한 과제로 여겨진다. 기존에는 이러한 복잡한 유동의 해석을 위해 전산유체역학(CFD)에 기반한 직접수치시물레이션(DNS)이 주로 활용되었지만 높은 계산 비용으로 인해 대규모 파라미터 탐색에는 한계가 존재한다.

† Corresponding Author, yykim@snu.ac.kr[9Point Times New Roman]

최근 딥러닝 기술의 발전은 이러한 계산비용 문제를 해결할 새로운 가능성을 제시하고 있다. 특히 시계열 예측에 강점을 지닌 순환신경망(RNN) 계열의 모델들은 유동장의 시계열적 변화를 효과적으로 학습할 수 있으며 그 중에서도 ConvLSTM은 시공간 정보를 동시에 고려할 수 있어 시계열 유체 문제 예측에 적합한 구조로 고려된다.

이에 본 연구에서는 ConvLSTM 기반의 Autoregression 모델을 제안하여 확률적으로 Input 을 모델의 예측값으로 대입하는 Scheduled sampling 기법을 이용하여 Ground Truth 의존성을 완화하고 Autoregression 성능을 향상시키고자 한다.

본 연구는 고비용 CFD 시뮬레이션의 대안으로서, 또는 예측 기반의 유동 제어, 데이터 기반 센서 시스템 등에 적용 가능한 효율적인 surrogate 모델을 제안하며 기존 예측 모델의 한계를 극복하는 방향성을 제시한다.

1.2 ConvLSTM(Convolution Long Short-Term Memory)⁽²⁾

ConvLSTM은 단기 강수량 예측(nowcasting) 문제를 시공간 예측으로 정의하면서 고안한 모델로, Channel x Row x Column 3 차원 텐서로 유지한다.⁽²⁾ 이 설계는 기존 LSTM이 놓치던 국소 이동·변형·합병과 같은 공간적 상호작용을 시간축과 동시에 학습할 수 있으며 파라미터 수는 줄면서도 수용 영역은 넓어진다. ConLSTM은 영상 프레임 예측, 의료 영상, 로봇 제어 뿐만 아니라 CFD 기반 유동장 예측으로 활용되었다.⁽³⁾

1.3 Scheduled Sampling⁽⁴⁾

Scheduled sampling은 순차 예측 모델의 노출 편향(Exposure Bias)을 완화하기 위한 알고리즘으로, Autoregression의 시퀀스 모델은 Teacher-forcing 단계에서 이전 시점 정답을 입력으로 사용하지만, 추론 단계에서는 모델이 생성한 값을 입력으로 사용한다. 이 훈련-추론 분포 불일치는 오류가 누적되면서 rollout 길이가 길수록 예측 품질을 급격히 떨어뜨리는 노출 편향 문제로 이어진다. Scheduled Sampling 기법은 기울기를 가진 확률로서 입력에 예측값을 넣어 간극을 점진적으로 메운다.

$$x_t^{\text{in}} = \begin{cases} y_{t-1} & \varepsilon_i \\ \hat{y}_{t-1} \sim P_\theta(y_{t-1} | h_{t-1}) & 1 - \varepsilon_i \end{cases}$$

2. 본 론

2.1 Data set 구축 및 전처리

본 연구에서 사용된 학습 데이터는 OpenFOAM을 활용하여 직접수치시뮬레이션(DNS) 방식으로 생성된 2차원 난류 시뮬레이션 데이터이다. 각 케이스는 Length: 6.283 x 6.283, Grid: 128 x 128 격자 해상도의 와류장(vorticity field)으로 구성되며, 총 50개의 랜덤한 초기 속도장 케이스를 0.1 초 간격으로 50 초까지 시뮬레이션하여 데이터를 확보하였다. 데이터는 에너지가 소실되고 인위적인 초기장이 사라진 후반부의 동역학을 집중적으로 학습하기 위해 각 케이스의 40 초~49.9 초 구간(dt = 0.1, 케이스 당 총 100 프레임)을 사용하였다.

데이터의 일반화 성능을 높이기 위해 회전 증강(rotational augmentation)을 수행하였으며 각 와류장은 0°, 90°, 180°, 270°로 회전되어 총 4배의 데이터를 확보하였다. 또한, 모든 와류장은 각 케이스의 첫 Time step(40s)의 RMS 값으로 정규화되어 비차원화되었다.




Fig. 1 Statistical analysis of the initial vorticity field to verify the presence of meaningful random turbulence.




Fig. 2 (1) Probability density function (PDF) of the vorticity field at the first timestep. (2) Average vorticity PDF over all timesteps for each simulation case(0~49cases).




Fig. 3 Temporal profile of the ensemble-averaged Reynolds number over 50 cases, with the shaded band representing the min-max range of stored data values at each timestep




Fig. 4 Visualization of rotational augmentations applied to Case 0. Vorticity fields are shown at 0°, 90°, 180°, and 270° rotations.

2.2 모델 구조 및 학습

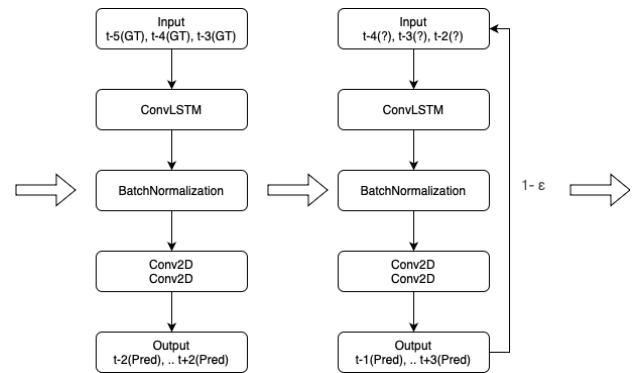


Fig. 5 Overview of the model training flow chart including scheduled sampling.

예측 모델은 ConvLSTM 기반의 autoregressive 구조로, ConvLSTM 계층은 시공간 정보를 동시에 학습할 수 있도록 5 차원 텐서를 입력받으며, CNN 기반 필터를 통해 공간적 패턴을 추출하고 LSTM 셀을 통해 시간적 종속성을 학습한다.

하나의 학습 샘플은 과거 3 프레임 $\{X_{t-3}, X_{t-2}, X_{t-1}\}$ 을 입력으로 받아 이후 5 프레임 $\{X_t, \dots, X_{t+4}\}$ 을 예측한다. 특히 시계열 예측에서 Ground Truth 에 과도하게 의존하는 문제를 줄이면서 예측값을 Input 으로 받는 Autoregression 모델에 적용할 수 있도록 Scheduled Sampling 을 적용

하였다. 초기 학습 단계에서는 Ground Truth 를 사용하여 모델을 학습하며 이후 학습 epoch 이 증가함에 따라 일정 확률로 이전 시점 모델의 예측값을 다음 입력으로 사용하도록 설정하였다. 이를 통해 학습과 추론 시의 분포 차이를 줄이고 오차 누적을 방지하였다. ConvLSTM2D(64, 5×5) \rightarrow BatchNorm \rightarrow Conv2D(32, 3×3 , ReLU) \rightarrow Conv2D(1, 3×3)로 구성된 학습 모델을 사용하였고, 손실은 각 단계별 MSE 를 5 스텝 평균한 값이다.

모델의 구조, 데이터 전처리, 최적화 조건은 모두 동일하며, 다르게 설정한 것은 “ 다음 입력을 GT(정답)으로 넣을지, 혹은 모델 예측값을 재귀적으로 넣을지 ” 를 결정하는 teacher-forcing 확률 ε 뿐이다. 이를 통해 scheduled sampling 이 예측 강건성에 미치는 순수 효과를 비교하였다. 예측값이 Input 으로 들어갈 양을 정량적으로 분석하면, 만약 $1 - \varepsilon = 0.1$ 일 때 teacher-forcing 확률은 $\varepsilon = 0.9$ 이므로, 학습 중 한 스텝에서 정답(GT)이 입력으로 선택될 확률이 90 %, 모델 예측값(Pred)이 선택될 확률이 10 %이다.

훈련 세트는 회전 증강을 포함해 160 개의 파일로 구성되어 있고, 각 파일에서 시드 3 장을 제외한 뒤 5 장을 예측하도록 잘라내면 92 개의 시퀀스가 만들어진다. 따라서 한 epoch 에는 총 14 720 시퀀스(160×92)가 지나가며 시퀀스마다 5 번의 autoregression 이 수행되어 모델 호출 횟수는 73,600 회($14\,720 \times 5$)가 된다.

확률 10 %에 해당하는 입력 프레임 수는 $73\,600 \times 0.1 = 7\,360$ 프레임으로, 이만큼이 예측값을 다시 입력으로 사용해 학습되는 데이터다. 나머지 90 %에 해당하는 66 240 프레임은 GT 프레임을 입력으로 사용한다.

(1) Teacher forcing

$\varepsilon = 1.0$ 으로 고정하여 항상 GT 프레임을 다음 입력으로 사용한다.

(2) Scheduled sampling - 0.9

초기 안정성을 높이기 위해 Epoch 10 에서 $\varepsilon = 0.90$ 이 되도록 선형으로 줄인다.

$$\varepsilon(e)=1.0 - 0.01e$$

(3) Scheduled sampling - 0.8

Epoch 10 에서 $\varepsilon = 0.80$ 이 되도록 기울기를 두 배로 하였다.

$$\varepsilon(e)=1.0 - 0.02e$$

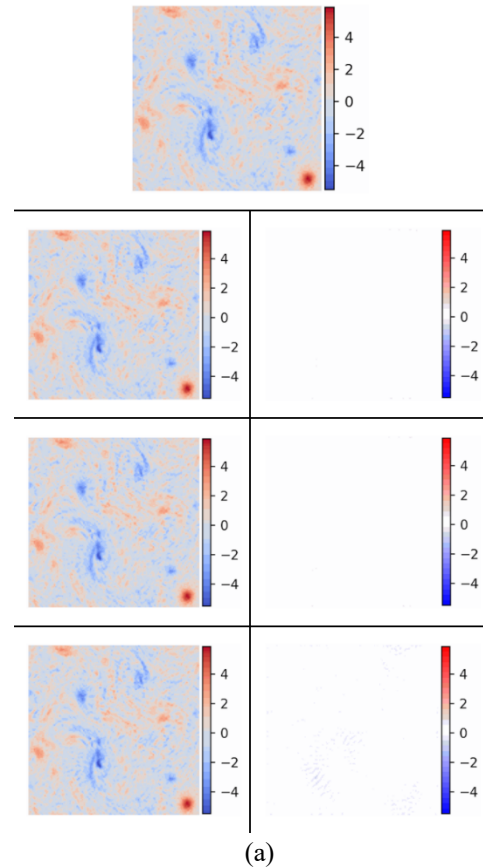
이후 1) Val-MSE 추이, 2) 에너지 스펙트럼 · 와류

PDF 보존 정도를 공통 지표로 제시한다. 이를 통해 teacher-forcing 만 사용했을 때 대비 scheduled sampling($\varepsilon = 0.9, 0.8$)이 장 · 단기 예측 성능과 통계 보존 특성에 어떤 영향을 미치는지 정량적으로 논의한다.

2.3 예측 결과 및 분석

2.3.1 Vorticity Fields 시각적 비교

Input 인 초기 3 프레임(40.0s, 40.1s, 40.2s)을 제외한 40.3s 부터의 예측장이다.



(a)


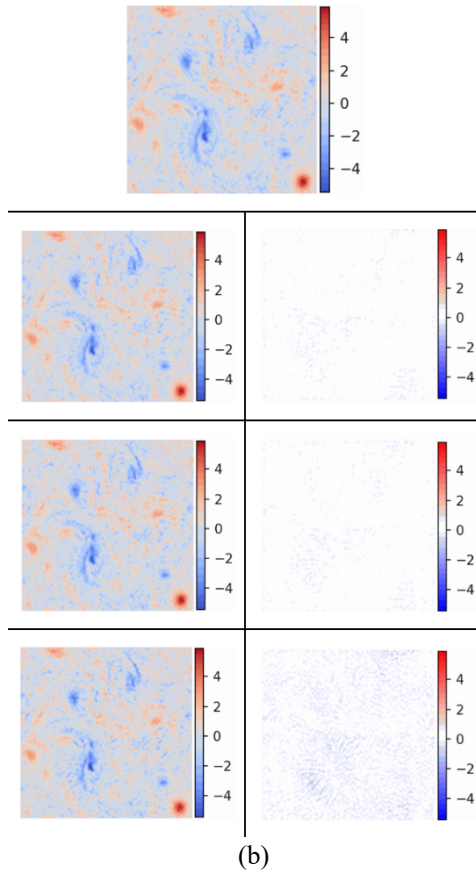

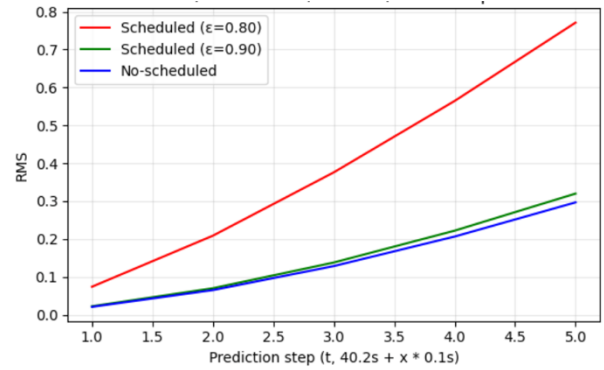


Fig. 6 Comparison of vorticity fields (left) and prediction results (right) value of Ground Truth(GT) – value of Prediction. From top to bottom: GT, Teacher Forcing model, Scheduled Sampling model with $\epsilon = 0.9$, $\epsilon = 0.8$ (a) Prediction of 40.3s (b) Prediction of 40.4s (c) Prediction of 40.6s (d) Prediction of 41.0s



2.3.2 RMS



(a)




Fig. 7 (a) RMS error between predictions and ground truth for the first 5 frames of each model. (b) RMS error averaged over all frames for each model.

2.3.3 Energy Spectrum


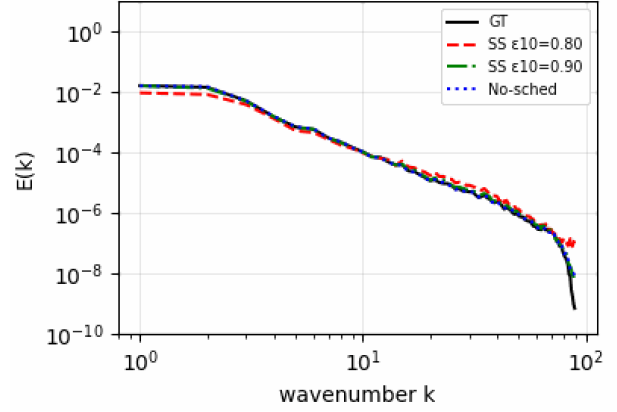



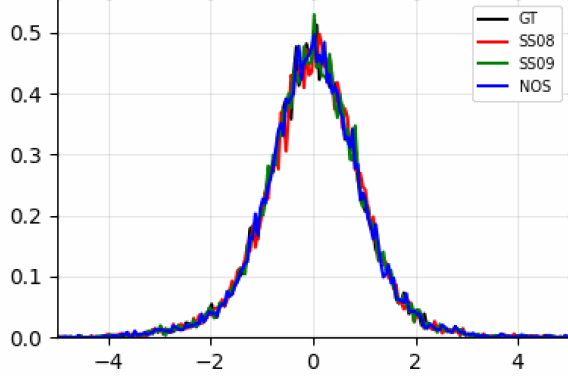



Fig. 8 Energy Spectrum of (a) 40.3s (b) 40.4s (c) 40.6s (d) 41.0s

2.3.4 Vorticity PDF (Probability Density Function)






(b)



(c)



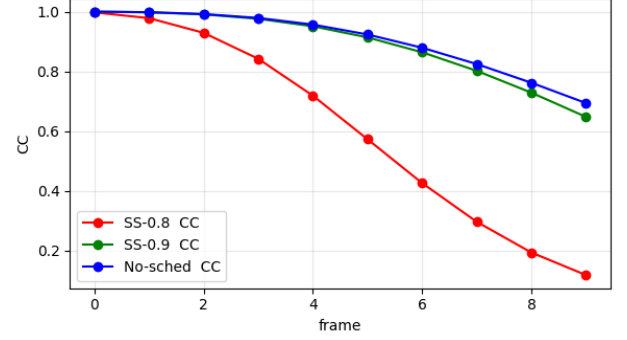
(d)

Fig. 9 Vorticity PDF of (a) 40.3s (b) 40.4s (c) 40.6s (d) 41.0s

2.3.5 Correlation Coefficient (CC)

초기 프레임 10 개에 대해 각 시점 t 에서 예측 와류장과 GT 와류장 사이의 2 차원 Pearson 상관계수 $CC(t)$ 는 다음과 같다.

$$CC(t) = \frac{\sum_{i,j} (\omega_{ij}^{\text{pred}}(t) - \bar{\omega}^{\text{pred}}(t)) (\omega_{ij}^{\text{GT}}(t) - \bar{\omega}^{\text{GT}}(t))}{\sqrt{\sum_{i,j} (\omega_{ij}^{\text{pred}}(t) - \bar{\omega}^{\text{pred}}(t))^2} \sqrt{\sum_{i,j} (\omega_{ij}^{\text{GT}}(t) - \bar{\omega}^{\text{GT}}(t))^2}}$$


Fig. 10 CC between predictions and ground truth over the first 10 frames.

2.3.6 SSIM (Structural Similarity Index Measure)

시각적인 일치도를 정량화 하기 위해 SSIM 지수를 사용하였다.

$$SSIM(t) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$$


$$\mu_x = \frac{1}{N} \sum_{i,j} \omega_{ij}^{\text{pred}}(t) \quad \mu_y = \frac{1}{N} \sum_{i,j} \omega_{ij}^{\text{GT}}(t)$$

$$\sigma_x^2 = \frac{1}{N-1} \sum_{i,j} (\omega_{ij}^{\text{pred}} - \mu_x)^2$$

$$\sigma_y^2 = \frac{1}{N-1} \sum_{i,j} (\omega_{ij}^{\text{GT}} - \mu_y)^2$$

$$\sigma_{xy} = \frac{1}{N-1} \sum_{i,j} (\omega_{ij}^{\text{pred}} - \mu_x)(\omega_{ij}^{\text{GT}} - \mu_y)$$

첫 10 개 프레임 대상 SSIM 지수는 다음과 같다.


Fig. 11 SSIM between predictions and ground truth over the first 10 frames

2.3.7 결과 분석

RMS, CC Score 는 Teacher Forcing(이하 TF > ϵ 0.9 > ϵ 0.8 순으로 우수하였다. 또한, RMS 곡선은 세 모델 모두 시간이 지남에 따라 증가하다가 서로 다른 값으로 수렴하였다. 초기 추론 단계에서 ϵ 0.8 모델이 가장 높은 RMS 추이를 보인 반면, 시간이 충분히 지남에 따라 ϵ 0.8 모델이 가장 낮은 RMS 로 수렴하였다. ConvLSTM 기반 autoregression 모델을 구축하고 teacher forcing(이하 TF)과 두 가지 확률의 scheduled sampling(이하 SS)($\epsilon_1, \epsilon_2 = 0.90, 0.80$) 을 비교·분석하였다. 모든 설정에서 입력 3 프레임으로부터 100 프레임(≈ 10 s)을 연속 예측하는 연구를 수행하였다. Cost 문제로 인하여 epoch 를 제한해 세 가지 모델 모두 10 epoch 까지 시행한 결과, 단기 예측에서는 TF 비중이 높은 모델이 유리하였으며 일정 수준의 Long-term Rollout 에서는 SS 가 누적 오차를 제어할 수 있음을 확인하였다. 이는 SS 의 도입이 장기 예측 안정성 측면에는 이점을 제공할 수 있다는 점을 시사하지만 충분한 epoch 가 주어지지 않은 환경에서는 ϵ 값의 감소가 초기 정확도를 희생시킨다는 것을 의미했다.

3. 결 론

본 연구는 Two dimensional vorticity field 에 대해 ConvLSTM 기반 autoregression 모델을 구축하고 teacher forcing(이하 TF)과 두 가지 확률의 scheduled sampling(이하 SS)(ϵ 0.90, 0.80) 을 비교·분석하였다. 모든 설정에서 입력 3 프레임으로부터 100 프레임(~ 10 s)을 연속으로 예측하는 연구를 수행하였다. 비용 문제로 epoch 를 제한해 세 가지 모델 모두 10 epoch 까지 학습한 결과, 단기 예측에서는 TF 비중이 높은 모델이 유리하였으며 일정 수준의 Long-term Rollout 에서는 ϵ 0.8 model 이 누적 오차가 가장 낮음을 확인하였다. 이는 SS 의 도입이 장기 예측 안정성 측면에는 이점을 제공할 수 있다는 점을 시사하지만 충분한 epoch 가 주어지지 않은 환경에서는 ϵ 값의 감소가 초기 정확도를 희생시킨다는 것을 의미했다.

후 기

향후 연구에서는 먼저 충분한 학습 epoch 를 확보하여 SS 의 진정한 효과를 검증할 필요가 있다.

본 연구에서는 계산 자원 제한으로 10 epoch 에서 비교했지만 동일한 설정을 수백 epoch 이상 학습할 경우 ϵ 값이 작은 모델이 초기 정확도 손실을 만회하고 장기 누적 오차까지 최소화할지 여부가 아직 불분명하다. 나아가 단기 제어(수 step 예측)와 장기 통계 예측(수십 step 이상)을 명확히 구분한 뒤, 단기에는 TF 비중을 높이고 장기에는 SS 비중을 높이는 이중 파라미터 전략 또는 적응형 SS(학습 중 손실 변화나 불확실도에 따라 ϵ 를 자동 조정하는 방식)을 도입하면 두 목표를 동시에 달성할 가능성이 있다. 마지막으로 본 연구는 단일 해상도(128 x 128), 단일 레이어 수 환경에서만 수행되었으므로 해상도 및 난류 Regime 을 다양화하여 ϵ 최적값과 모델 일반화 능력을 종합적으로 평가할 필요가 있다. 이러한 후속 연구를 통해 SS 의 epoch 의존성, 장·단기 성능 trade-off, 그리고 물리적 타당성을 정밀하게 규명함으로써 난류 예측 모델의 실전 적용 가능성을 한층 높일 수 있을 것으로 기대한다.

참고문헌

(References)

- (1) Kraichnan, R. H., & Montgomery, D., 1980, Two-dimensional turbulence. Reports on Progress in Physics, 43(5), 547.
- (2) Shi, X., Chen, Z., Wang, H., Yeung, D. Y., Wong, W. K., & Woo, W. C., 2015, Convolutional LSTM network: A machine learning approach for precipitation nowcasting. Advances in neural information processing systems, 28.
- (3) Liu, C., 2025, Convolutional Long Short-Term Memory Neural Networks Based Numerical Simulation of Flow Field.
- (4) Bengio, S., Vinyals, O., Jaitly, N., & Shazeer, N., 2015, Scheduled sampling for sequence prediction with recurrent neural networks. Advances in neural information processing systems, 28.